

这是更好的收敛。去掉 `fashion` 后，项目可以专注回答一个更清楚的 NLP 问题：

Mem0在多 session 对话中发生错误时，问题主要来自 memory formation、retrieval，还是最终 answer generation？不同memory表示方式会如何影响这些阶段？

建议项目名称：

Where Does Conversational Memory Fail? A Stage-Wise Evaluation of Mem0 on LoCoMo

最终研究问题

可以设置三个 RQ：

- **RQ1:** Mem0与普通 raw-dialogue RAG相比，是否能提高 LoCoMo问答表现？
- **RQ2:** Raw dialogue、LoCoMo observations和 Mem0生成的facts，哪种memory representation更适合检索？
- **RQ3:** 错误主要发生在 memory formation、retrieval还是answer generation？不同类型问题是否表现不同？

推荐实验设计

1. Oracle诊断

直接把 LoCoMo提供的 gold evidence交给回答模型：

Gold evidence → LLM → Answer

这代表回答模型在“检索完全正确”时的表现上限。

如果 gold evidence下仍答错，说明是 reasoning/generation问题，而不是memory问题。

2. Baselines

配置	Memory来源	Retrieval
B0	最近一个session	不使用长期检索
B1	原始dialogue turns	Dense retrieval
B2	LoCoMo observations	Dense retrieval
B3	LoCoMo session summaries	Dense retrieval
M0	Mem0默认生成的facts	Dense retrieval
M1	你们调整后的atomic episodic facts	Dense retrieval

这里先让所有方法使用相同 retriever，避免把 memory表示和retrieval算法混在一起。

3. Retrieval实验

选出表现最好的memory representation, 然后比较:

- Dense retrieval;
- BM25;
- BM25 + dense hybrid。

这样实验是分阶段的:

```
retriever memory representation
memory representation retrieval
```

不需要把所有方法做成几十种排列组合。

你们修改Mem0的具体内容

不要声称发明新的 temporal memory, 而是做一个明确的 extraction ablation:

Mem0 Default

```
Caroline moved to Boston.
Caroline accepted a new job.
```

Atomic Episodic Extraction

```
[Session 5 | Caroline | moved_to | Boston | Source D127]
[Session 5 | Caroline | accepted | new job | Source D129]
```

抽取规则要求:

- 每条memory只包含一个atomic event;
- 明确保留speaker;
- 保留session和时间;
- 保留source dialogue ID;
- 不把推测当成已确认事实;
- 不把两个事件错误合并;
- 不添加对话中不存在的信息。

你们的结论应写成:

We study whether atomic, provenance-preserving episodic memories improve retrieval and QA.

而不是:

We invent episodic memory for Mem0.

评估指标

End-to-end QA

- Answer F1;
- 按 single-hop、multi-hop、temporal、open-domain和adversarial分类报告。

Retrieval

- Recall@1;
- Recall@5;
- Recall@10;
- MRR, 可选。

Memory formation

抽取一小部分样本人工检查:

- 是否保留关键事实;
- 是否产生hallucinated memory;
- speaker是否正确;
- 时间是否正确;
- 是否保留必要的因果或事件关系。

效率

- 每个问题检索的token数;
- ingestion时间;
- retrieval latency, 可选。

错误分类

最终可以把错误分成:

Formation failure

→ memory

Retrieval failure

→ memory top-k

Reasoning failure

→ memory

Temporal failure

→

Multi-hop failure

→

这会成为项目最重要的分析贡献。

三人分工

- 成员一：LoCoMo数据处理、gold evidence oracle、B0/B1 baseline；
- 成员二：Mem0 OSS集成、memory生成、provenance记录；
- 成员三：BM25/dense/hybrid retrieval、统一评估；
- 三人共同：atomic episodic extraction设计和错误分析。

对教授的项目描述

We will build a multi-session conversational agent using Mem0 and evaluate it on LoCoMo. Rather than comparing multiple black-box memory frameworks, we will conduct a controlled, stage-wise study of memory formation, retrieval, and answer generation. We will compare raw dialogue turns, LoCoMo observations and summaries, Mem0's default memories, and atomic provenance-preserving episodic memories under the same retrieval setup. We will then evaluate retrieval methods and analyze failures across single-hop, multi-hop, and temporal questions.

这个版本不需要自建数据集，也不依赖 fashion应用；它的贡献是**可控的 memory representation实验、阶段性诊断和 LoCoMo错误分析**。这比单纯跑 Mem0 benchmark更完整，也更符合教授原始题目。